Introdução ao Pandas ("panel data")

Fonte: https://pt.wikipedia.org/wiki/Panda-gigante

?

https://pandas.pydata.org/docs/

Professor: Alex Pereira

Metodologia

- Zona de Desenvolvimento Proximal - ZDP (Vygotsky [1])
  - a distância entre o nível de desenvolvimento real,
    - ✓determinado pela capacidade de resolver tarefas de forma independente,
  - e o nível de desenvolvimento potencial,
    - ✓determinado por desempenhos possíveis, com ajuda de adultos ou de colegas mais avançados ou mais experientes.

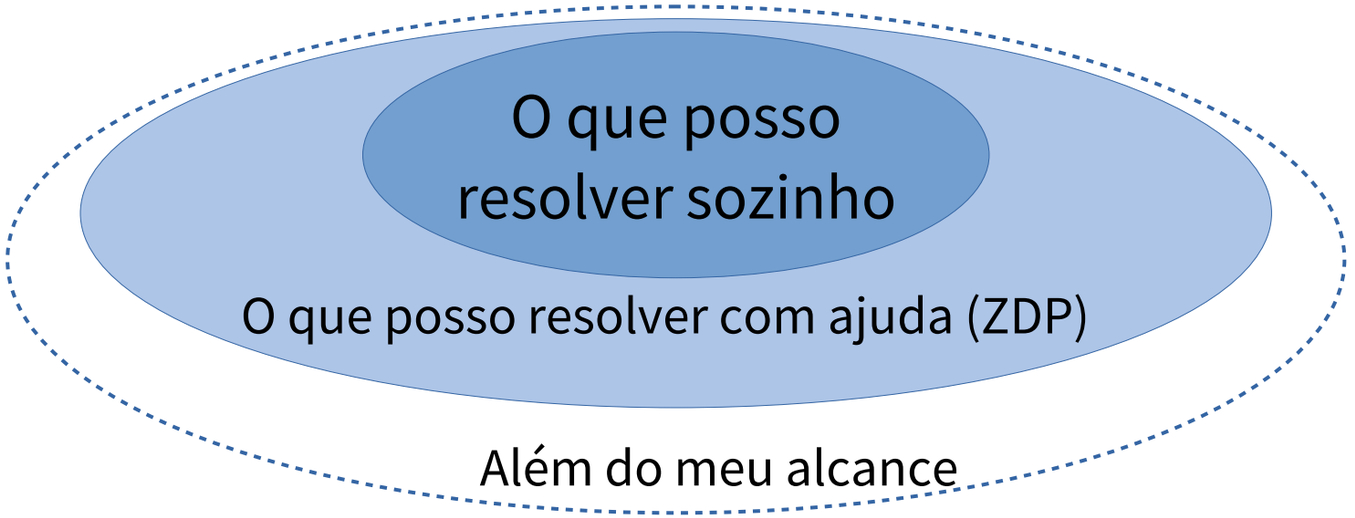

[1] - Kozulin, Gindis, Ageyev, Miller, (2003), Vygotsky's Educational Theory in Cultural Context, Cambridge University Press

Revisão

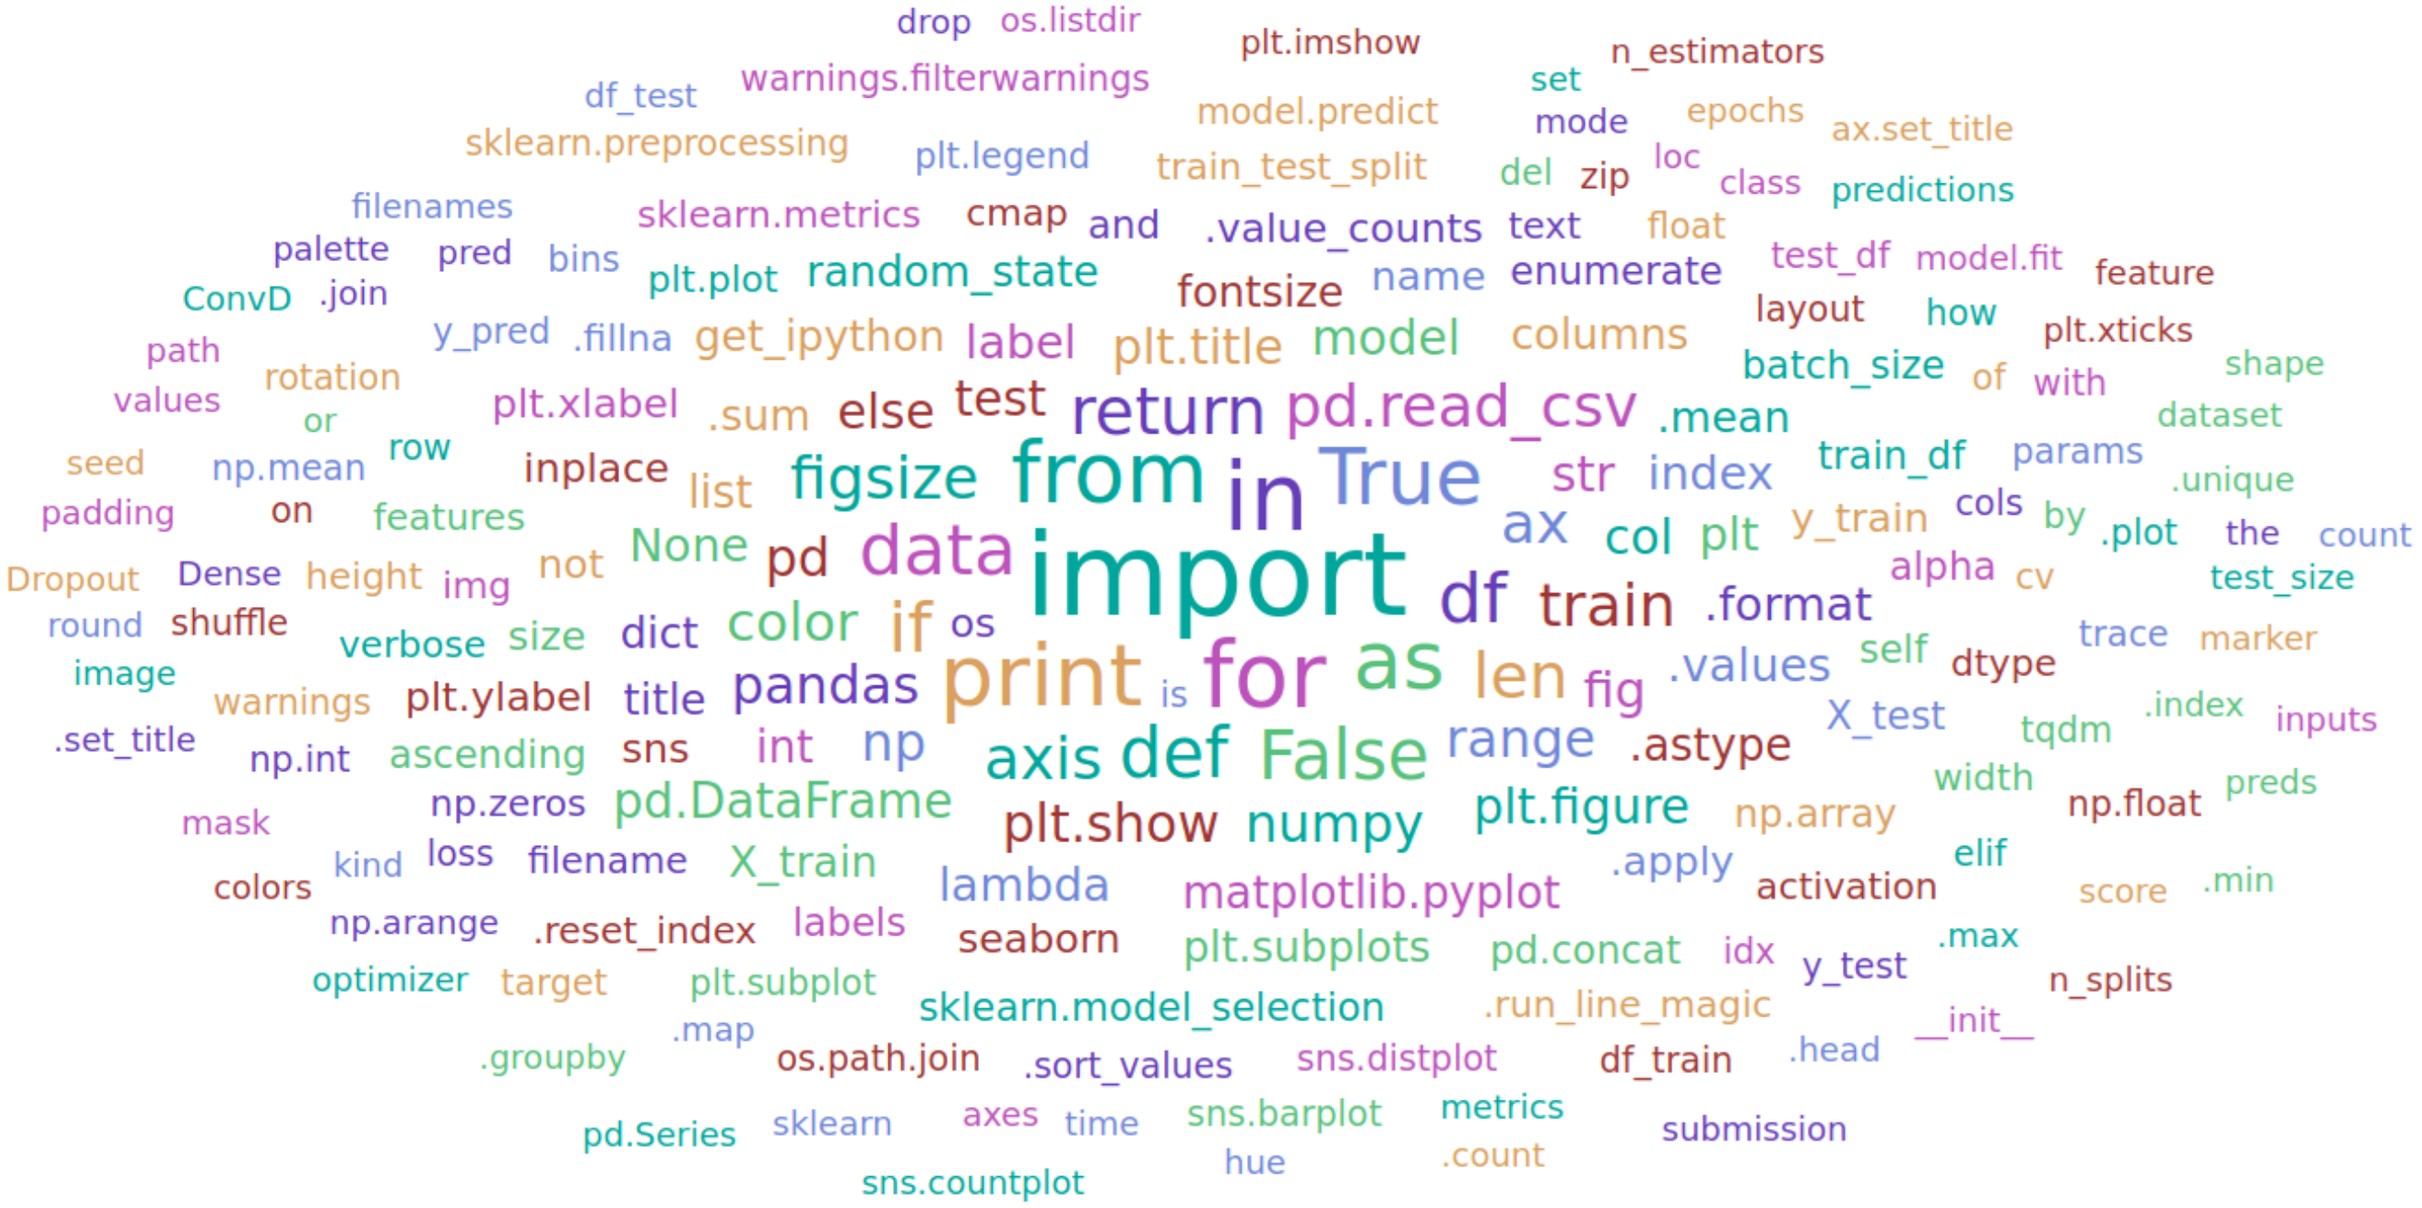
drop
os.listdir
plt.imshow
n_estimators
warnings.filterwarnings
set
df_test
model.predict
mode
epochs
ax.set_title
sklearn.preprocessing
plt.legend
train_test_split
del
zip
loc
class
predictions
filenames
sklearn.metrics
cmap
and
.value_counts
text
float
palette
pred
bins
plt.plot
random_state
name
enumerate
test_df
model.fit
feature
ConvD
.join
fontsize
layout
how
plt.xticks
path
y_pred
.fillna
get_ipython
label
plt.title
model
columns
batch_size
of
with
shape
values
rotation
plt.xlabel
.sum
else
test
return
pd.read_csv
.mean
dataset
or
seed
np.mean
row
inplace
list
figsize
from
in
True
str
index
train_df
params
.unique
padding
on
features
None
pd
data
import
ax
col
plt
y_train
cols
by
.plot
the
count
Dropout
Dense
height
img
not
df
train
alpha
cv
test_size
round
shuffle
verbose
size
dict
color
if
os
.format
trace
marker
image
pandas
print
is
for
as
len
fig
.values
self
dtype
warnings
plt.ylabel
title
X_test
.index
inputs
.set_title
np.int
ascending
sns
int
np
axis
def
False
range
.astype
tqdm
width
preds
mask
np.zeros
pd.DataFrame
plt.show
numpy
plt.figure
np.array
np.float
kind
loss
filename
X_train
.apply
elif
colors
lambda
matplotlib.pyplot
activation
score
.min
np.arange
.reset_index
labels
seaborn
plt.subplots
pd.concat
idx
.max
optimizer
target
plt.subplot
sklearn.model_selection
y_test
n_splits
.map
.run_line_magic
__init__
.groupby
os.path.join
.sort_values
sns.distplot
df_train
.head
pd.Series
sklearn
axes
time
sns.barplot
metrics
submission
hue
.count
sns.countplot

Pandas

Limpeza e análise de dados
fácil e rápido em Python

- https://deepnote.com : Notebook colaborativo

Pandas

- Adota o estilo idiomático de computação baseada em arrays
  - do NumPy
    - ✓ Preferência por processar dados sem loops
- NumPy armazena dados homogêneos
  - Pandas foi projetado para trabalhar com dados tabulares e heterogêneos
- Se tornou open source em 2010
  - conta com mais de 800 colaboradores

Series

- **`import pandas as pd`**
- É um objeto (semelhante ao Array) de uma dimensão
  - contendo uma sequência de valores, e
  - um array de rótulos
    - ✓ chamado index (índice)

```
In [11]: obj = pd.Series([4, 7, -5, 3])

In [12]: obj
Out[12]:
0    4
1    7
2   -5
3    3
dtype: int64
```

Series

- Pode-se indicar o seu array de índices

```
In [15]: obj2 = pd.Series([4, 7, -5, 3], index=['d', 'b', 'a', 'c'])

In [16]: obj2
Out[16]:
d    4
b    7
a   -5
c    3
dtype: int64
```

Series

- Use o índice para acessar o valor
  - Pode ser usada em contextos onde você usaria um dicionário

```
In [18]: obj2['a']
Out[18]: -5

In [19]: obj2['d'] = 6

In [20]: obj2[['c', 'a', 'd']]
Out[20]:
c    3
a   -5
d    6
dtype: int64
```

Verificar se um elemento pertence a uma Serie

- Usando o keyword in
  - Pode-se verificar se um elemento pertence ao **índice** de um a Serie

```
obj2 = pd.Series([4, 7, -5, 3], index=['d', 'b', 'a', 'c'])
```

```
1  # Verifique se o índice 'c' está presente
2  'c' in obj2
```

```
True
```

Series

- Use o operações semelhantes às operações NumPy
  - filtro com um array de booleanos, multiplicação por escalar e funções matemáticas

```
In [21]: obj2[obj2 > 0]
Out[21]:
d    6
b    7
c    3
dtype: int64
```

```
In [22]: obj2 * 2
Out[22]:
d    12
b    14
a   -10
c     6
dtype: int64
```

```
In [23]: np.exp(obj2)
Out[23]:
d      403.428793
b     1096.633158
a        0.006738
c       20.085537
dtype: float64
```

Series

- Criando uma Serie com um dicionário
  - mas especificando seu próprio índice separadamente
    - ✓sdata= {'Ohio': 35000, 'Texas': 71000, 'Oregon': None, 'Utah': None}

```
In [29]: states = ['California', 'Ohio', 'Oregon', 'Texas']

In [30]: obj4 = pd.Series(sdata, index=states)

In [31]: obj4
Out[31]:
California        NaN
Ohio          35000.0
Oregon        16000.0
Texas         71000.0
dtype: float64
```

Valores Ausentes/Indisponíveis (NA)

- Verifique quais elementos são NA
  - e vice versa

```
In [32]: pd.isnull(obj4)
Out[32]:
California     True
Ohio          False
Oregon        False
Texas         False
dtype: bool
```

```
In [33]: pd.notnull(obj4)
Out[33]:
California    False
Ohio           True
Oregon         True
Texas          True
dtype: bool
```

```
In [34]: obj4.isnull()
Out[34]:
California     True
Ohio          False
Oregon        False
Texas         False
dtype: bool
```

Aritmética com Series

- Automaticamente alinha os valores pelo índice

```
In [35]: obj3
Out[35]:
Ohio      35000
Oregon    16000
Texas     71000
Utah       5000
dtype: int64
```

```
In [36]: obj4
Out[36]:
California        NaN
Ohio          35000.0
Oregon        16000.0
Texas         71000.0
dtype: float64
```

```
In [37]: obj3 + obj4
Out[37]:
California        NaN
Ohio          70000.0
Oregon        32000.0
Texas        142000.0
Utah              NaN
dtype: float64
```

DataFrame

- Representa uma tabela retangular de dados
- Contém uma coleção de colunas ordenadas
  - Onde cada coluna pode conter diferentes tipos de dados
    - ✓ numérico, string, boolean e etc
- Tem uma linha e uma coluna de índices

```
data = {'state': ['Ohio', 'Ohio', 'Ohio', 'Nevada', 'Nevada', 'Nevada'],
        'year': [2000, 2001, 2002, 2001, 2002, 2003],
        'pop': [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
frame = pd.DataFrame(data)
```

```
In [45]: frame
Out[45]:
   pop    state  year
0  1.5     Ohio  2000
1  1.7     Ohio  2001
2  3.6     Ohio  2002
3  2.4   Nevada  2001
```

Mostre as primeiras linhas de um DataFrame

- Use o método head

```
In [46]: frame.head()
Out[46]:
   pop    state  year
0  1.5     Ohio  2000
1  1.7     Ohio  2001
2  3.6     Ohio  2002
3  2.4   Nevada  2001
4  2.9   Nevada  2002
```

Uma coluna pode ser recuperada como uma Serie

- A notação .nome_coluna não funciona
  - Quando o nome da coluna contém espaços
    - ✓ Acostume-se a usar a notação ['nome_coluna']

```
In [51]: frame2['state']
Out[51]:
one          Ohio
two          Ohio
three        Ohio
four       Nevada
five       Nevada
six        Nevada
Name: state, dtype: object
```

```
In [52]: frame2.year
Out[52]:
one       2000
two       2001
three     2002
four      2001
five      2002
six       2003
Name: year, dtype: int64
```

Colunas podem ser modificadas por atribuição

- Atribuição de um valor único ou de um array numpy

```
In [54]: frame2['debt'] = 16.5

In [55]: frame2
Out[55]:
       year   state  pop  debt
one    2000    Ohio  1.5  16.5
two    2001    Ohio  1.7  16.5
three  2002    Ohio  3.6  16.5
four   2001  Nevada  2.4  16.5
five   2002  Nevada  2.9  16.5
six    2003  Nevada  3.2  16.5
```

```
In [56]: frame2['debt'] = np.arange(6.)

In [57]: frame2
Out[57]:
       year   state  pop  debt
one    2000    Ohio  1.5   0.0
two    2001    Ohio  1.7   1.0
three  2002    Ohio  3.6   2.0
four   2001  Nevada  2.4   3.0
five   2002  Nevada  2.9   4.0
six    2003  Nevada  3.2   5.0
```

Atribuir uma coluna que não existe criará uma nova coluna

```
In [61]: frame2['eastern'] = frame2.state == 'Ohio'

In [62]: frame2
Out[62]:
       year   state  pop  debt  eastern
one    2000    Ohio  1.5   NaN     True
two    2001    Ohio  1.7  -1.2     True
three  2002    Ohio  3.6   NaN     True
four   2001  Nevada  2.4  -1.5    False
five   2002  Nevada  2.9  -1.7    False
six    2003  Nevada  3.2   NaN    False
```

del exclui as colunas (como em um dicionário)

```
In [63]: del frame2['eastern']

In [64]: frame2.columns
Out[64]: Index(['year', 'state', 'pop', 'debt'], dtype='object')
```

Criar um DataFrame a partir de um dicionário de dicionários

```
In [65]: pop = {'Nevada': {2001: 2.4, 2002: 2.9},
    ....:          'Ohio': {2000: 1.5, 2001: 1.7, 2002: 3.6}}

In [66]: frame3 = pd.DataFrame(pop)


In [67]: frame3
Out[67]:
      Nevada  Ohio
2000     NaN   1.5
2001     2.4   1.7
2002     2.9   3.6
```

O atributo values retorna um array 2d com os valores

```
In [74]: frame3.values
Out[74]:
array([[ nan,  1.5],
       [ 2.4,  1.7],
       [ 2.9,  3.6]])
```

Removendo entradas de uma Serie

```
In [105]: obj = pd.Series(np.arange(5.), index=['a', 'b', 'c', 'd', 'e'])
```

```
In [106]: obj
Out[106]:
a    0.0
b    1.0
c    2.0
d    3.0
e    4.0
dtype: float64
```

```
In [107]: new_obj = obj.drop('c')
```

```
In [108]: new_obj
Out[108]:
a    0.0
b    1.0
d    3.0
e    4.0
dtype: float64
```

Removendo entradas de um DataFrame

- Pode-se remover linhas ou colunas

```
In [110]: data = pd.DataFrame(np.arange(16).reshape((4, 4)),
   .....:                     index=['Ohio', 'Colorado', 'Utah', 'New York'],
   .....:                     columns=['one', 'two', 'three', 'four'])
```

	one	two	three	four
Ohio	0	1	2	3
Colorado	4	5	6	7
Utah	8	9	10	11
New York	12	13	14	15

```
In [112]: data.drop(['Colorado', 'Ohio'])
Out[112]:
          one  two  three  four
Utah        8    9     10    11
New York   12   13     14    15
```

```
In [113]: data.drop('two', axis=1)
Out[113]:
          one  three  four
Ohio        0      2     3
Colorado    4      6     7
Utah        8     10    11
New York   12     14    15
```

Atribuindo valor num DataFrame

	one	two	three	four
Ohio	0	1	2	3
Colorado	4	5	6	7
Utah	8	9	10	11
New York	12	13	14	15

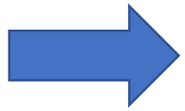

```
In [135]: data[data < 5] = 0

In [136]: data
Out[136]:
```

	one	two	three	four
Ohio	0	0	0	0
Colorado	0	5	6	7
Utah	8	9	10	11
New York	12	13	14	15

```
In [134]: data < 5
Out[134]:
```

	one	two	three	four
Ohio	True	True	True	True
Colorado	True	False	False	False
Utah	False	False	False	False
New York	False	False	False	False

Filtro e Seleção

	one	two	three	four
Ohio	0	1	2	3
Colorado	4	5	6	7
Utah	8	9	10	11
New York	12	13	14	15

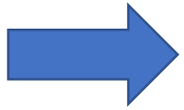

```
In [130]: data['two']
Out[130]:
Ohio          1
Colorado      5
Utah          9
New York     13
Name: two, dtype: int64
```

```
In [131]: data[['three', 'one']]
Out[131]:
          three  one
Ohio          2    0
Colorado      6    4
Utah         10    8
New York     14   12
```

```
In [133]: data[data['three'] > 5]
Out[133]:
          one  two  three  four
Colorado    4    5      6     7
Utah        8    9     10    11
New York   12   13     14    15
```

Seleção com o Operador loc e iloc

- Seleção de linhas ou linhas e colunas

	one	two	three	four
Ohio	0	1	2	3
Colorado	4	5	6	7
Utah	8	9	10	11
New York	12	13	14	15

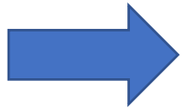

```
In [138]: data.iloc[2, [3, 0, 1]]
Out[138]:
four    11
one      8
two      9
Name: Utah, dtype: int64
```

```
In [137]: data.loc['Colorado', ['two', 'three']]
Out[137]:
two      5
three    6
Name: Colorado, dtype: int64
```

Filtro e Seleção - Resumo

- .loc faz filtros
  - de linhas pelo nome das linhas no índice ou por um vetor de booleanos;
  - de linhas e colunas pelo nome das linhas no índice e pelos nomes das colunas; e
  - de linhas e colunas por um vetor de booleanos (True e False).
- .iloc faz filtros
  - de linhas e colunas pelo número das linhas no índice e pelo número das colunas.
- []
  - de colunas pelos nomes das colunas; e
  - de linhas por um vetor de booleanos (True e False).

Filtro e Seleção - Exemplos

```
data = {'state': ['Ohio', 'Ohio', 'Ohio', 'Nevada', 'Nevada', 'Nevada'],
'year': [2000, 2001, 2002, 2001, 2002, 2003],
'pop': [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
frame = pd.DataFrame(data, index=['a', 'b', 'c', 'd', 'e', 'f'])
```

```
# Nome(s) de coluna(s)
print(frame.loc['a'])
# Nome(s) de linha(s) e nomes de coluna(s)
print(frame.loc['a', 'pop'])
# Vetor de booleano e nome de coluna
print(frame.loc[[True, True, False, False, False, False], 'pop'])
# Vetor(es) de booleano(s)
print(frame.loc[[True, True, False, False, False, False], [True, True, False]])
print(frame.iloc[0:2, 1]) # Indice(s) da(s) linha(s) e coluna(s)
print(frame['pop']) # Nome(s) da(s) colunas
print(frame[[True, True, False, False, False, False]]) # Vetor de booleano
```

Prática no Colab Notebook

- Escolham por onde começar: Teoria, Warmup ou Exercícios;
  - As soluções dos warmups já estão publicadas;
  - As soluções dos exercícios extra serão disponibilizadas no dia seguinte;
- É esperado que não terminem todos os exercícios durante a aula;
  - Façam o restante ao longo da semana.
- Ao final da lista você será capaz executar tarefas relevantes