Pandas e Fontes de dados

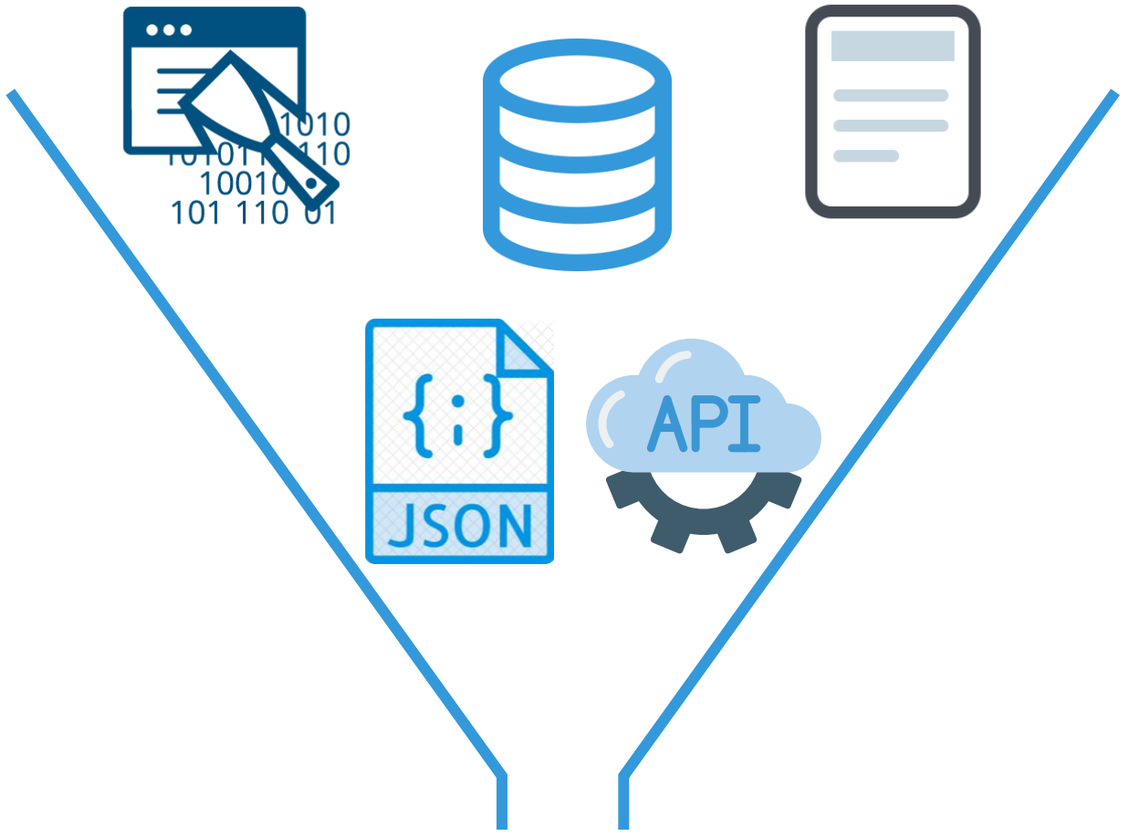

Professor: Alex Pereira

Produtividade com o uso da IA

- Ethan Molick mediu
  - Com um RCT

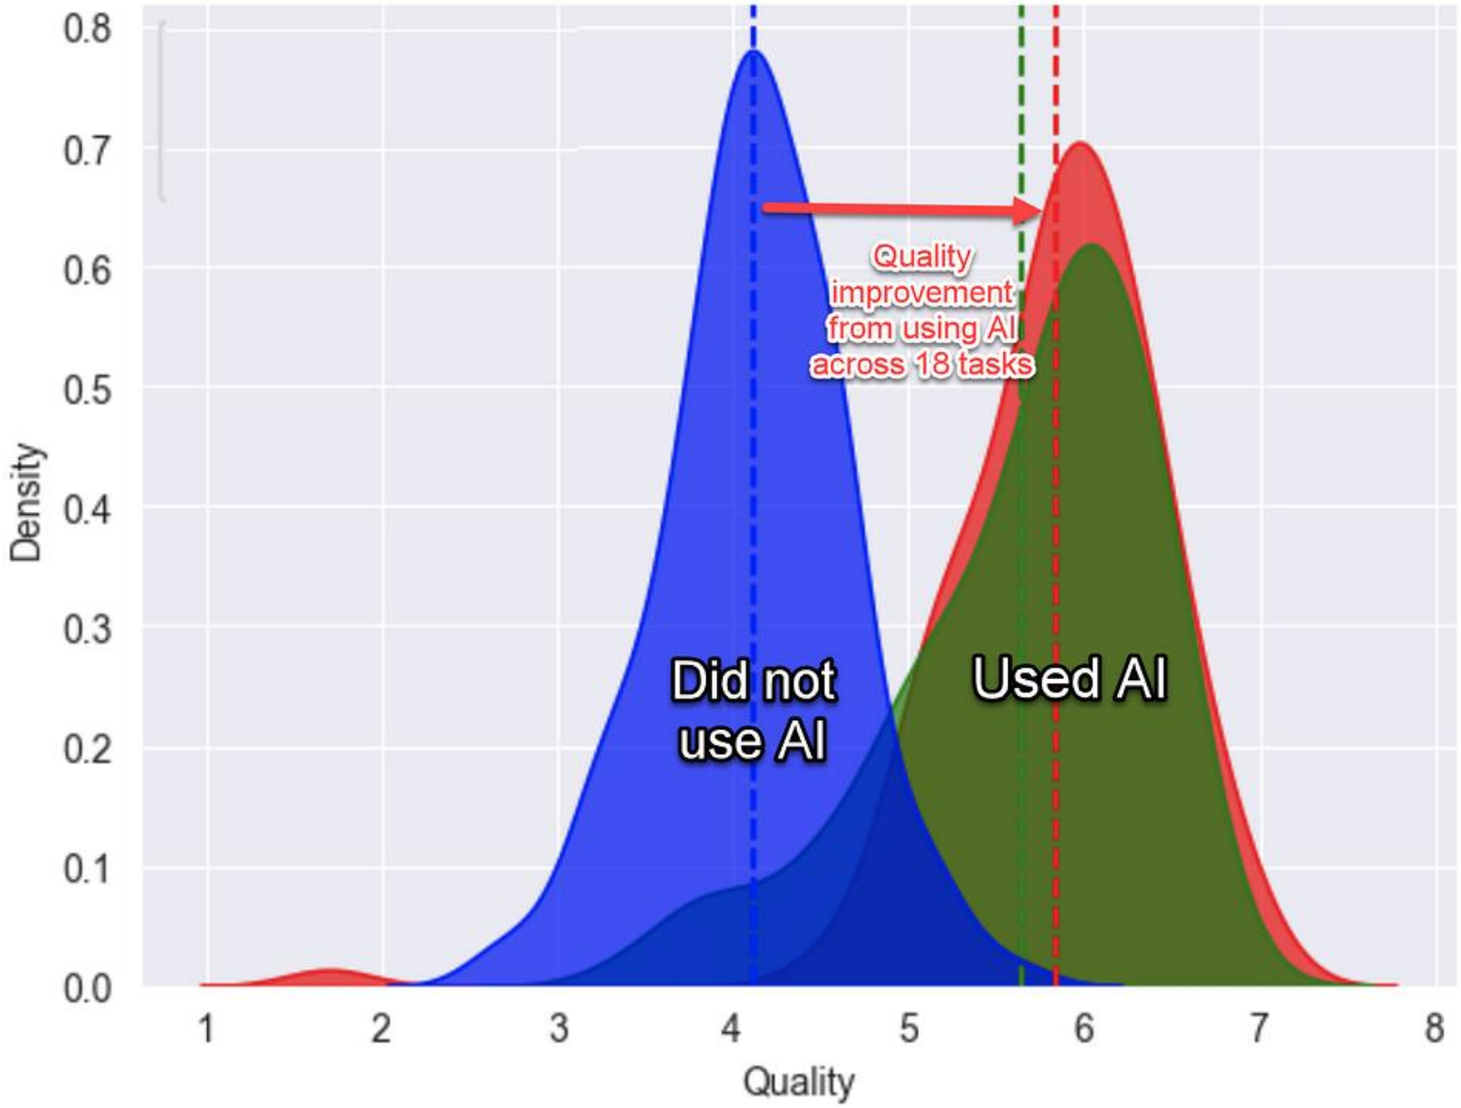

Função apply

- Aplica uma função ao longo de um eixo (linhas ou colunas) de um DataFrame
  - padrão: axis=0 (rows/index)

	b	d	e
Utah	0.807185	-1.135001	-1.071895
Ohio	1.943592	0.151843	1.507981
Texas	-0.374554	0.076108	1.625286
Oregon	0.252045	1.726434	-0.300007

```
3 f = lambda x: x.max()*2
4 frame.apply(f, axis='rows')
```

```
b     3.887184
d     3.452868
e     3.250571
dtype: float64
```

```
2 frame.apply(f, axis='columns')
```

```
Utah      1.614371
Ohio      3.887184
Texas     3.250571
Oregon    3.452868
dtype: float64
```

Função map

- Aplica uma função a cada elemento (element-wise)

	b	d	e
Utah	-1.551399	0.617767	0.045852
Ohio	1.079766	0.075621	1.174516
Texas	-0.339443	1.589292	-0.064619
Oregon	1.450546	-2.259592	0.348973

```
format = lambda x: '%.2f' % x
frame.map(format)
```

	b	d	e
Utah	-1.55	0.62	0.05
Ohio	1.08	0.08	1.17
Texas	-0.34	1.59	-0.06
Oregon	1.45	-2.26	0.35

Sumarização e Estatística Descritiva

```
     one   two
a   1.40   NaN
b   7.10  -4.5
c    NaN   NaN
d   0.75  -1.3
```

```
In [232]: df.sum()
Out[232]:
one    9.25
two   -5.80
```

```
In [233]: df.sum(axis='columns')
Out[233]:
a    1.40
b    2.60
c     NaN
d   -0.55
```

mean (média)

- Os valores de NA são excluídos,
  - a menos que toda a fatia
    - ✓ linha ou coluna seja NA.
  - Isso pode ser desativado com a opção skipna

	one	two
a	1.40	NaN
b	7.10	-4.5
c	NaN	NaN
d	0.75	-1.3

```
1  df.mean(axis='columns')
```

```
a    1.400
b    1.300
c      NaN
d   -0.275
```

```
In [234]: df.mean(axis='columns', skipna=False)
Out[234]:
a       NaN
b     1.300
c       NaN
d    -0.275
```

describe (resumo de várias estatísticas)

- Computa várias estatísticas

	one	two
a	1.40	NaN
b	7.10	-4.5
c	NaN	NaN
d	0.75	-1.3

```
In [237]: df.describe()
Out[237]:
              one       two
count    3.000000  2.000000
mean     3.083333 -2.900000
std      3.493685  2.262742
min      0.750000 -4.500000
25%      1.075000 -3.700000
50%      1.400000 -2.900000
75%      4.250000 -2.100000
max      7.100000 -1.300000
```

Exemplo de uso do read_csv / read_excel

```
pd.read_excel('./pib_municipios.xlsx', sheet_name='Tabela', skiprows=3)
```

	Unnamed: 0	Unnamed: 1	Unnamed: 2	2007	2009	2011	2013
0	MU	1100015.0	Alta Floresta D'Oeste (RO)	191364	256986	280510	341325.0
1	MU	1100023.0	Ariquemes (RO)	905203	1133095	1651885	1799853.0
2	MU	1100031.0	Cabixi (RO)	49166	69776	77217	96365.0
3	MU	1100049.0	Cacoal (RO)	814890	985479	1259024	1433254.0
4	MU	1100056.0	Cerejeiras (RO)	143270	190902	260142	353270.0

Exemplo de uso do read_csv / read_excel

- Neste curso, descubra a URL na página do github

```
1 pd.read_excel('https://github.com/alexlopespereira/curso_ciencia_dados2020/r
```

	Unnamed: 0	Unnamed: 1	Unnamed: 2	2007	2009	2011	2013
0	MU	1100015.0	Alta Floresta D'Oeste (RO)	191364	256986	280510	341325.0
1	MU	1100023.0	Ariquemes (RO)	905203	1133095	1651885	1799853.0
2	MU	1100031.0	Cabixi (RO)	49166	69776	77217	96365.0
3	MU	1100049.0	Cacoal (RO)	814890	985479	1259024	1433254.0
4	MU	1100056.0	Cerejeiras (RO)	143270	190902	260142	353270.0

Solução para os principais problemas de leitura de arquivos read_csv/read_excel

- sep="," (somente no read_csv)
  - caracter de separação entre as colulas. Padrão é a vírgula
- skiprows=*N*
  - Ignora as primeiras *N* linhas do arquivo
    - ✓ Encontre o valor de N por tentative e erro.
- skipfooter=*N*
  - Ignora as últimas *N* linhas do arquivo
- na_values="-" ou na_values=["-", "..."]
  - Especifica o(s) valor(es) que devem ser interpretados como NA
- encoding="UTF-8" (somente no read_csv)
  - Especifica o padrão de codificação dos caracteres do arquivo texto
- dtype={'cod_munic': str, 'cod_uf': str}
  - Especifica o tipo de dado que uma dada coluna deve ter no dataframe
- decimal=',' (o padrão é o ponto)
  - Use a vírgula quando as casas decimais estiverem separadas por vírgula)
- Ver exemplo no Jupyter notebook

Descartando valores faltantes (NA ou NaN)

- Aceita o argumento `inplace=True`

```
In [15]: from numpy import nan as NA

In [16]: data = pd.Series([1, NA, 3.5, NA, 7])

In [17]: data.dropna()
Out[17]:
0    1.0
2    3.5
4    7.0

In [18]: data[data.notnull()]
Out[18]:
0    1.0
2    3.5
4    7.0
```

Equivalentes

Preenchendo valores faltantes

- `fillna` também aceita o argumento `inplace=True`

```
In [27]: df = pd.DataFrame(np.random.randn(7, 3))
```

```
In [33]: df.fillna(0)
Out[33]:
          0         1         2
0 -0.204708  0.000000  0.000000
1 -0.555730  0.000000  0.000000
2  0.092908  0.000000  0.769023
3  1.246435  0.000000 -1.296221
4  0.274992  0.228913  1.352917
5  0.886429 -2.001637 -0.371843
6  1.669025 -0.438570 -0.539741
```

```
In [34]: df.fillna({1: 0.5, 2: 0})
Out[34]:
          0         1         2
0 -0.204708  0.500000  0.000000
1 -0.555730  0.500000  0.000000
2  0.092908  0.500000  0.769023
3  1.246435  0.500000 -1.296221
4  0.274992  0.228913  1.352917
5  0.886429 -2.001637 -0.371843
6  1.669025 -0.438570 -0.539741
```

Preenchendo valores faltantes

- `fillna` possui um método de preenchimento `ffill`

```
In [37]: df = pd.DataFrame(np.random.randn(6, 3))

In [38]: df.iloc[2:, 1] = NA

In [39]: df.iloc[4:, 2] = NA

In [40]: df
Out[40]:
          0         1         2
0  0.476985  3.248944 -1.021228
1 -0.577087  0.124121  0.302614
2  0.523772       NaN  1.343810
3 -0.713544       NaN -2.370232
4 -1.860761       NaN       NaN
5 -1.265934       NaN       NaN
```

```
In [41]: df.fillna(method='ffill')
Out[41]:
          0         1         2
0  0.476985  3.248944 -1.021228
1 -0.577087  0.124121  0.302614
2  0.523772  0.124121  1.343810
3 -0.713544  0.124121 -2.370232
4 -1.860761  0.124121 -2.370232
5 -1.265934  0.124121 -2.370232
```

Remover duplicatas

```
In [45]: data = pd.DataFrame({'k1': ['one', 'two'] * 3 + ['two'],
    ....:                     'k2': [1, 1, 2, 3, 3, 4, 4]})
```

```
In [46]: data
Out[46]:
    k1  k2
0  one   1
1  two   1
2  one   2
3  two   3
4  one   3
5  two   4
6  two   4
```

```
In [47]: data.duplicated()
Out[47]:
0    False
1    False
2    False
3    False
4    False
5    False
6     True
dtype: bool
```

```
In [48]: data.drop_duplicates()
Out[48]:
    k1  k2
0  one   1
1  two   1
2  one   2
3  two   3
4  one   3
5  two   4
```

Indexação Hierárquica

- Possibilita mais de um nível de indexação num eixo

```
data = pd.Series(np.random.randn(9),
                 index=[['a', 'a', 'a', 'b', 'b', 'c', 'c', 'd', 'd'],
                        [1, 2, 3, 1, 3, 1, 2, 2, 3]])
```

```
a  1   -0.204708
   2    0.478943
   3   -0.519439
b  1   -0.555730
   3    1.965781
c  1    1.393406
   2    0.092908
d  2    0.281746
   3    0.769023
```

Filtro com lista

```
In [14]: data.loc[['b', 'd']]
Out[14]:
b  1   -0.555730
   3    1.965781
d  2    0.281746
   3    0.769023
```

Filtro no 2º Nível

```
In [15]: data.loc[:, 2]
Out[15]:
a    0.478943
c    0.092908
d    0.281746
```

Resumo estatístico por nível

state		Ohio		Colorado
color		Green	Red	Green
key2	key1			
1	a	0	1	2
	b	6	7	8
2	a	3	4	5
	b	9	10	11

```
In [27]: frame.sum(level='key2')
Out[27]:
state  Ohio     Colorado
color Green Red    Green
key2
1          6   8        10
2         12  14        16
```

Erros que vocês vão cometer

- Fazer uma operação que espera uma string
  - sobre uma coluna que tem dados numéricos (int ou float)
- Fazer uma operação que espera um dado numérico
  - sobre uma coluna que tem dados em formato de string
- Para sair desse problema, investigue usando pd.Dataframe.info()

```
Data columns (total 9 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   nivel       5570 non-null   object
 1   cod_ibge7   5570 non-null   int64
 2   municipio   5570 non-null   object
 3   2007        5570 non-null   object
 4   2009        5570 non-null   object
```

string

inteiro

Depois de encontrar a causa do problema você precisará usar um desses argumentos para reler o arquivo

- sep="," (somente no read_csv ou sep=";")
  - caracter de separação entre as colulas. Padrão é a vírgula
- skiprows=*N*
  - Ignora as primeiras *N* linhas do arquivo
    - ✓ Encontre o valor de N por tentative e erro.
- skipfooter=*N*
  - Ignora as últimas *N* linhas do arquivo
- na_values="-" ou na_values=["-", "..."]
  - Especifica o(s) valor(es) que devem ser interpretados como NA
- encoding="UTF-8" (somente no read_csv)
  - Especifica o padrão de codificação dos caracteres do arquivo texto
- dtype={'cod_munic': str, 'cod_uf': str}
  - Especifica o tipo de dado que uma dada coluna deve ter no dataframe
- decimal=',' (o padrão é o ponto)
  - Use a vírgula quando as casas decimais estiverem separadas por vírgula)

Prática no Colab Notebook

- Faça o restante dos exercícios da aula;
- Há exercícios extra.

A IA ainda não está boa carregar arquivos tabulares

- A IA ainda não está boa para inferir os argumentos das funções do pandas que leem arquivos e transformam num DataFrame.
- **Você precisará, a priori, descobrir** quais são esses argumentos e solicitar que a IA os utilize para ler os arquivos.
  - Por exemplo, visualizando as primeiras e ultimas linhas dos arquivos